

Simulación modelo esférico

Karol Stefanny Ayala López John Anderson Guarín López
Liliana Catalina Lara Ruiz Germán Camilo Vásquez Herrera

Librerías


```
library(geoR)  
library(MASS)  
library(ade4)
```

Punto 1

Generar un enmallado regular tamaño 100.

```
# Enmallado regular de tamaño 100  
grid<-expand.grid(seq(0,9),seq(0,9))  
plot(grid, col="blue", pch=16, xlab="x", ylab="y",  
      main="Región de Estudio y\nPuntos de Muestreo")
```

Región de Estudio y Puntos de Muestreo



Punto 2

Simular un campo aleatorio Gaussiano estacionario de media μ con estructura de covarianza esférica.

En este caso, utilizamos $\mu = 17$, $\sigma^2 = 11$ y $\phi = 4$.

```
# Simulación campo Gaussiano estacionario de media mu con covarianza esférica

# Asignación de valores
n <- 100
mu <- 17
sigma <- 11
phi <- 4

# Generación de datos correlacionados

## Distancia entre los sitios (Wij)
distan <- dist(grid, diag=TRUE, upper=TRUE)
distan <- as.matrix(distan)

## Modelo de covarianza esferica
```

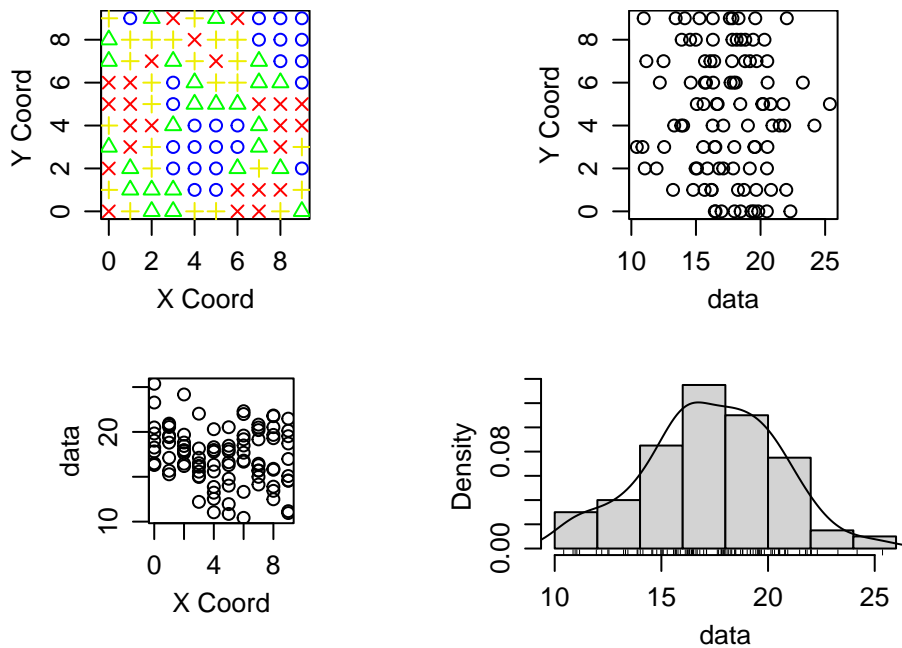
```

covarianza<-cov.spatial(distan, cov.model<-"spherical", cov.pars=c(sigma,phi))

## Vector de medias
medias_cte<-rep(mu,n)

## Simulación de 100 valores de una normal multivariada
set.seed(17112000)
normal_cte <- mvrnorm(1,medias_cte,covarianza)
datoscte <- cbind(grid[,1],grid[,2],normal_cte)
datoscte <- as.geodata(datoscte, coords=1:2, var=3)
plot(datoscte)

```



Punto 3

Dibujar el modelo teórico de covarianza y el estimado con los datos simulados.


```

# Modelo teórico de covarianza y modelo estimado

## Variograma teórico
matplot(distan,sigma-covarianza, type="p",xlab="h",ylab="Variograma",
        main = "Modelo teórico")


```

Modelo teórico



```
## Variograma estimado
variograma <- variog(datoscte,option = "smooth",messages = FALSE)
plot(variograma$u,variograma$v, xlab="h",ylab="Variograma",
      main = "Modelo estimado", pch=16)
```

Modelo estimado



Punto 4

Encuentre un IC del 95% para μ empleando las expresiones que tengan en cuenta la correlación espacial.

```
# IC del 95% para mu usando correlación espacial esférica

## Estimación de mu
uno<-rep(1,n)
mu_est<-(ginv(t(unos)%%ginv(covarianza)%%unos))%%(t(unos)%%ginv(covarianza)%%normal_cte)

## Varianza de mu
var_mu<-ginv(t(unos)%%ginv(covarianza)%%unos)

li <- mu_est-1.96*sqrt(var_mu) # LI
ls <- mu_est+1.96*sqrt(var_mu) # LS
IC <- cbind(li,ls)
rownames(IC)<-" "
colnames(IC)<-c("LI","LS");IC
```

LI	LS
15.62069	19.06343

El intervalo de confianza resultante es $IC_{95\%}(\mu) = [15.62069, 19.06343]$

Punto 5

Repita los pasos 2 y 4 hasta encontrar 100 IC.

```
# Repetir de 2 a 4 ####

LI<-NULL
LS<-NULL

set.seed(17112000)
for(i in 1:100){
  normal_cte <- mvrnorm(1,medias_cte,covarianza)
  mu_est <- (ginv(t(unos))%*%ginv(covarianza)%*%unos))%*%
    (t(unos)%*%ginv(covarianza)%*%normal_cte)
  LI[i]<-mu_est-1.96*sqrt(var_mu)
  LS[i]<-mu_est+1.96*sqrt(var_mu)
}
```

Punto 6

¿Cuántos IC contienen el verdadero valor de μ ?

```
# Cuantos IC contienen el verdadero valor de mu ####
tot <- 0
for(i in 1:100){
  if(mu>=LI[i] & mu<=LS[i]){
    tot<-tot+1
  }
}
tot
```

[1] 97

En total, 97 de los 100 intervalos de confianza contienen el verdadero valor de $\mu = 17$. Lo cual tiene sentido pues construimos el intervalo de confianza con $\alpha = 5\%$ de significancia, por lo que no es raro que la cantidad de intervalos que contienen al verdadero valor del parámetro sea cercano a 95. Si repitiéramos esto pero para 1000, 10000, 100000, se acercará cada vez más a una cobertura del 95%.

Punto 7

¿Cuál es su conclusión del ejercicio?

Como hemos observado en nuestras sesiones, al construir intervalos de confianza sin considerar la correlación espacial presente en los datos, hemos notado una cobertura deficiente. No obstante, al incorporar esta estructura en nuestra estimación, hemos logrado obtener intervalos con una cobertura más acorde a lo esperado.